數位影像處理 HW1 技術報告

組員姓名與學號：待填

1 轉換核心性質：Q1 與 Q2 證明

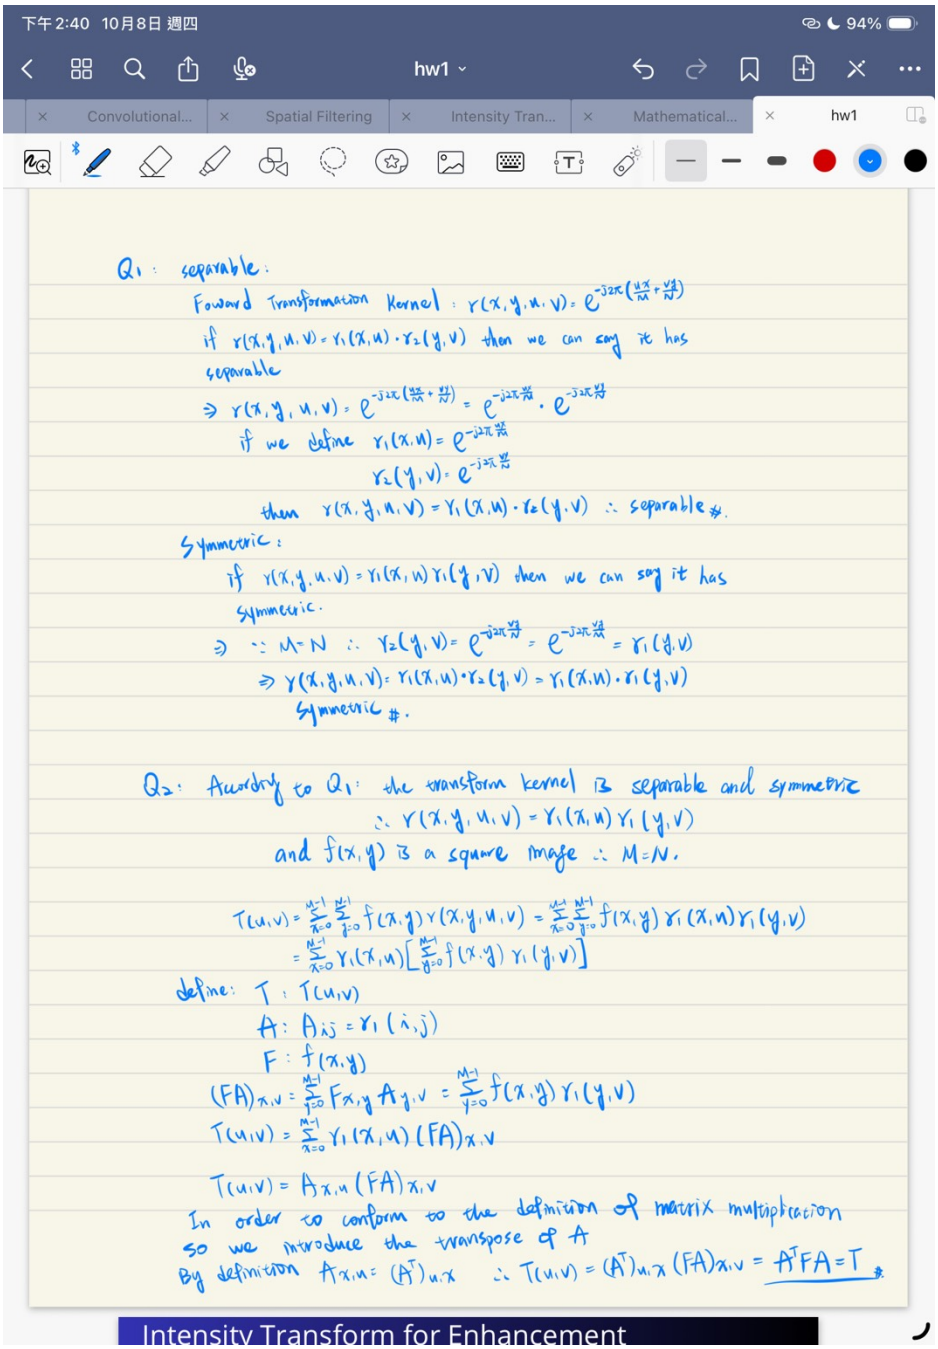

图 1: Q1 與 Q2 的手寫證明原稿。

2 強度轉換：Gamma 處理前後比較

2.1 實驗目的與轉換原理

此題實作 Gamma 轉換，觀察不同指數對影像亮度與細節可見度的影響。除了題目指定的鐵塔影像外，另外使用夜間建築、逆光港口及室內貓咪三個案例，比較不同影像條件下的處理效果。所有影像先由 BGR 轉為灰階，再進行相同的逐像素轉換。

令輸入像素灰階為 $I(x,y) \in \{0,\dots,255\}$，先正規化為 $r(x,y) = I(x,y)/255$，再套用冪次轉換：

$$s(x,y) = c\,[r(x,y)]^{\gamma}, \qquad c>0,\ \gamma>0. \tag{1}$$

程式將結果乘回 255、截斷至 $[0,255]$，最後轉為 `uint8`。由於截斷後的數值皆為非負數，此處轉為整數相當於向下取整：

$$G(x,y) = \left\lfloor \mathrm{clip}\!\left(255c\left[\frac{I(x,y)}{255}\right]^{\gamma}, 0, 255\right)\right\rfloor. \tag{2}$$

此題固定 $c=1$。對 $0<r<1$，當 $\gamma>1$ 時，$r^{\gamma}<r$，因此影像會變暗；當 $0<\gamma<1$ 時，$r^{\gamma}>r$，因此影像會變亮。例如 $r=0.5$ 時，$\gamma=2$ 得到 0.25，而 $\gamma=0.5$ 得到約 0.707。若 $\gamma=1$，轉換在理論上保持原強度。

2.2 實驗參數與程式實作

表 1 列出 `intensity_enhanecement.py` 中實際使用的參數。這些設定用來展示增亮與變暗的差異，並非透過參數搜尋求得的最佳值。其中檔名標為 bright 的影像含有局部強光與大片陰影，以下依畫面內容稱為逆光港口，不將整張影像直接視為過曝。

表 1: Gamma 實驗案例與參數

案例	c	γ	選擇目的
鐵塔（指定影像）	1.0	2.0	降低亮度，觀察鋼架與人物的可見變化。
夜間建築（偏暗）	1.0	0.5	提高暗部亮度，觀察建築與前景細節。
逆光港口（局部強光）	1.0	2.0	降低中間灰階亮度，檢查亮部與陰影的取捨。
室內貓咪（一般曝光）	1.0	1.5	示範較溫和的變暗效果，檢查是否有改善。

Listing 1: Gamma 轉換的核心實作

```python
def gamma_transform(input_image, c=1.0, gamma=1.0):
    normalized_image = input_image.astype(np.float64) / 255.0
    output_image = c * (normalized_image ** gamma)
    output_image = np.clip(output_image * 255.0, 0, 255).astype(np.uint8)
    return output_image
```

程式 1 為 `spatial_operations.py` 中的核心運算，先轉成浮點數再正規化，使冪次運算對應式 (1)；NumPy 的 `**` 逐元素計算冪次，最後以 `np.clip` 限制合法強度範圍，轉成八位元無號整數

以供存檔。由於最後會量化，處理可能合併原本不同的灰階值，並非完美的映射。

2.3　指定案例：鐵塔影像

圖 2 為 `brian-pennington.jpeg` 的處理結果。原圖的天空、地面及人物周邊偏亮，鐵塔下方鋼架呈現較淡的灰階。使用 $c = 1$、$\gamma = 2$ 後，鋼架、欄杆及人物衣物的中間灰階降低，與周圍亮部的視覺差異較容易辨識；地面也由接近白色變為較深的灰色。另一方面，原本已經很暗的結構也會變暗，不能將所有變化都視為細節增加。

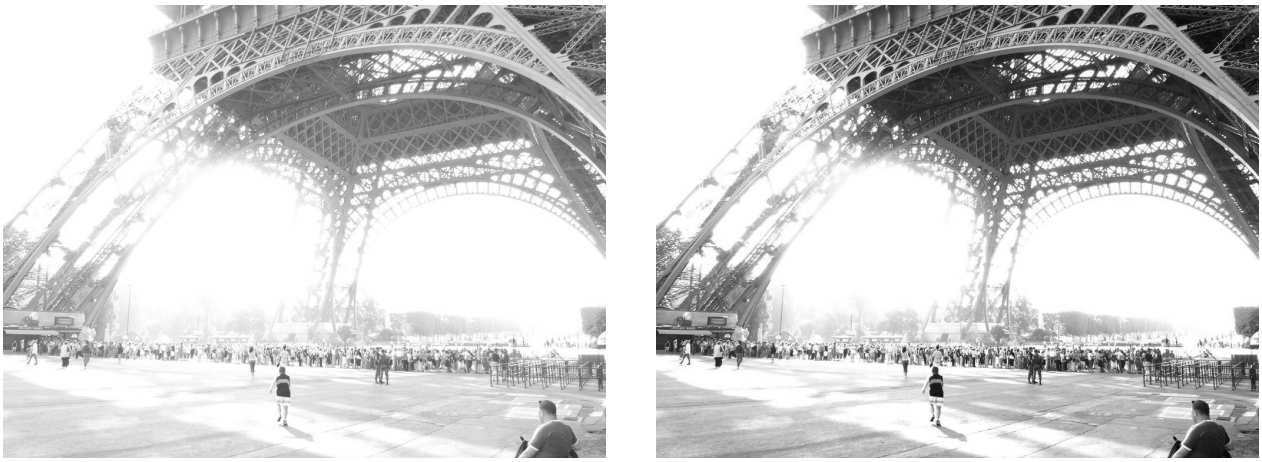

(a) 處理前：灰階原圖　(b) 處理後：Gamma 轉換

图 2: 鐵塔影像前後比較，$c = 1$、$\gamma = 2$。

影像平均灰階由 212.65 降為 186.87，符合整體變暗的預期。但大片天空依然接近純白；實測灰階值為 255 的像素比例，處理前後皆為 28.64%。因為 $c = 1$ 時 $1^{\gamma} = 1$，純白像素不會變暗；即使調整 Gamma，也無法從已飽和的像素恢復原先場景資訊。因此，此設定可以降低非飽和區域的亮度，卻不能完整修復過曝。

2.4　額外案例一：夜間建築影像

圖 3 的原圖下半部偏暗，屋頂、水塔、牆面與樹木不易辨認。使用 $c = 1$、$\gamma = 0.5$ 後，天空與建築的亮度提高，水塔輪廓、牆面與前景線條較容易辨識；平均灰階由 66.59 增加至 111.88。這顯示在原本仍有灰階差異的暗部，Gamma 小於 1 有助於提高細節可見度。

(a) 處理前：灰階原圖　　(b) 處理後：Gamma 轉換

图 3: 夜間建築影像前後比較，$c = 1$、$\gamma = 0.5$。

不過提亮後建築與天空中的顆粒、塊狀紋理也較明顯，所以此方法沒有同時完成降噪；而輸入為純黑的像素仍保持純黑。這個案例說明，增亮有助於觀看現存細節，但不能保證影像品質在所有方面都有提升。

2.5 額外案例二：逆光港口影像

圖 4 同時包含明亮太陽、水面反光與較暗的船身及岸邊。使用 $c = 1$、$\gamma = 2$ 後，天空與一般水面的中間灰階下降，而太陽及最亮的反光依然突出。平均灰階由 108.44 降為 56.31，表示這次轉換造成明顯的整體變暗。

(a) 處理前：灰階原圖　(b) 處理後：Gamma 轉換

图 4: 逆光港口影像前後比較，$c = 1$、$\gamma = 2$。

此設定的缺點是船身、岸邊建築與陰影區域也進一步變暗，部分輪廓較不易辨認。經過八位元量化後，純黑像素比例由約 0.012% 增加到 2.068%，顯示部分低灰階值被壓到零。因此，$\gamma = 2$ 雖然降低大部分像素的亮度，卻不適合用來同時保留這張逆光照片的暗部細節。這個案例反映了單一全域 Gamma 無法分別調整強光區與陰影區。

2.6　額外案例三：室內貓咪影像

圖 5 的原圖具有較亮的天花板與牆面，以及較暗的鋼架與貓咪。使用 $c = 1$、$\gamma = 1.5$ 後，天花板和牆面呈現較深灰階，但貓咪與鋼架同樣變暗；平均灰階由 127.34 降為 96.07。這個變化符合 $\gamma > 1$ 的理論，卻沒有讓原本偏暗的主體更容易觀看。

(a) 處理前：灰階原圖　(b) 處理後：Gamma 轉換

图 5: 室內貓咪影像前後比較，$c = 1$、$\gamma = 1.5$。

因此，對原本曝光尚可、主體又位於陰影中的圖片，套用變暗的 Gamma 並不一定有利。參數應配合想強調的區域與觀看目的選擇，不能只因程式成功執行就判定結果較好。

2.7　數值比較與整體討論

表 2 的數值直接由上述八張結果 PNG 的像素計算，不是由顯示縮圖估計。對大小為 $H \times W$ 的影像 J，平均灰階定義為

$$\mu(J) = \frac{1}{HW} \sum_{y=0}^{H-1} \sum_{x=0}^{W-1} J(x, y). \tag{3}$$

表 2: 各案例的平均灰階比較；灰階範圍為 0 至 255。

案例	γ	處理前	處理後	差值（後減前）
鐵塔	2.0	212.65	186.87	−25.78
夜間建築	0.5	66.59	111.88	+45.29
逆光港口	2.0	108.44	56.31	−52.12
室內貓咪	1.5	127.34	96.07	−31.27

四組結果皆符合 $c = 1$ 時的冪次轉換特性：$\gamma < 1$ 提亮，$\gamma > 1$ 變暗。平均灰階只能用來確認整體亮度變化，不能單獨代表對比、細節或主觀品質。鐵塔案例降低了非飽和區域的亮度；夜間建築案例提高了部分暗部細節的可見度；逆光港口與室內貓咪案例則顯示，變暗也可能犧牲主體及陰

影資訊。Gamma 是對整張影像套用相同規則的逐像素運算，參數選擇必須兼顧原始亮度分布、想觀察的區域與量化造成的資訊損失。

實作者：待填。　**審查者：**待填。
審查意見：待實際檢查後填寫。

3 強度轉換：直方圖等化

3.1 實驗目的與轉換原理

此題自行實作直方圖等化 (Histogram Equalization)，以題目指定的 `images/dark.jpg` 測試，觀察原本集中在低灰階的影像，經過強度重新分配後，亮度、對比與細節可見度的變化。與前一節需要設定 c 與 γ 的 Gamma 轉換不同，此方法直接由輸入影像的灰階分布決定映射，不需要手動設定 Gamma 指數。

對八位元灰階影像，令 n_k 為灰階值 k 的像素數，影像大小為 $H \times W$，正規化直方圖定義為

$$p(k) = \frac{n_k}{HW}, \qquad k = 0, 1, \ldots, 255. \tag{4}$$

各灰階的比例相加應為 1。累積分布函數與本程式使用的強度映射為

$$C(k) = \sum_{j=0}^{k} p(j), \tag{5}$$

$$T(k) = \lfloor 255\, C(k) \rfloor . \tag{6}$$

最後以 $G(x, y) = T(I(x, y))$ 更新每個像素。由於累積分布不會隨 k 增加而下降，映射具有單調不減的性質，不會將原本較暗的灰階映射得比原本較亮的灰階更亮。本實作直接使用上述 CDF 公式，未額外扣除最小非零 CDF。

3.2 測試資料與執行方法

測試由 `intensity_enhanecement.py` 的直方圖等化部分執行。在 `hw1` 資料夾執行以下指令，即可讀取圖片並輸出結果：

Listing 2: 實驗執行指令

```
python intensity_enhanecement.py
```

程式會先將輸入彩色圖片轉為灰階，再呼叫自行實作的 `histogram_equalization`，不是第三方直方圖等化 API。影像結果與中間圖表皆儲存在 `results` 資料夾。表 3 列出本次實驗需要檢查的五張圖片。

表 3: 直方圖等化的實驗輸出與檢查目的

檔名	檢查目的
`dark-gray.png`	確認灰階原圖的偏暗區域及細節可見度。
`equalized.png`	比較等化後的文字、紋理、暗部與亮部。
`histogram-input.png`	觀察輸入像素在各灰階的比例。
`histogram-mapping.png`	觀察輸入灰階與輸出灰階的對應關係。
`histogram-output.png`	觀察等化後的灰階分布。

3.3 程式實作與說明

以下程式片段取自 `spatial_operations.py`，省略原有註解與未參與運算的初始複製。函式先建立 `results` 輸出資料夾，再依序完成直方圖、CDF 映射與像素更新。

Listing 3: 計算並繪製正規化輸入直方圖

```
histogram = np.bincount(input_image.ravel(), minlength=256)
normalized_histogram = histogram / input_image.size

plt.bar(np.arange(256), normalized_histogram, width=1.0)
plt.xlabel("Input intensity")
plt.ylabel("Normalized frequency")
plt.title("Normalized Input Histogram")
plt.savefig(folder_out + "/histogram-input.png")
plt.close()
```

程式 3 先將二維像素攤平成一維，再利用 `np.bincount` 統計各灰階的像素數。

參數 `minlength=256` 使沒有出現的灰階也保留對應位置，再除以總像素數，得到式 (4) 的比例。長條圖的橫軸是灰階值，縱軸是像素比例，而不是像素數量。

Listing 4: 建立並繪製 CDF 強度映射

```
cumulative_distribution = np.cumsum(normalized_histogram)
intensity_mapping = np.floor(255 * cumulative_distribution).astype(np.uint8)

plt.plot(np.arange(256), intensity_mapping)
plt.xlabel("Input intensity")
plt.ylabel("Output intensity")
plt.title("Histogram Equalization Mapping")
plt.savefig(folder_out + "/histogram-mapping.png")
plt.close()
```

程式 4 以 `np.cumsum` 對灰階比例累加，得到式 (5) 的累積分布。乘以 255 後向下取整，建立長度為 256 的灰階查詢表。曲線顯示每一個輸入灰階將被換成什麼輸出值，因此能用來解釋影像為何變亮，以及哪些原始灰階被拉開或合併。

Listing 5: 更新像素並繪製正規化輸出直方圖

```
output_image = intensity_mapping[input_image]

output_histogram = np.bincount(output_image.ravel(), minlength=256)
normalized_output_histogram = output_histogram / output_image.size
plt.bar(np.arange(256), normalized_output_histogram, width=1.0)
plt.xlabel("Output intensity")
plt.ylabel("Normalized frequency")
plt.title("Normalized Output Histogram")
plt.savefig(folder_out + "/histogram-output.png")
plt.close()
```

程式 5 以原圖像素值直接索引查詢表，使每個位置取得對應的新灰階；影像的寬高與像素位置保持相同。接著重新統計輸出灰階比例，以便與輸入分布比較。此步驟也能檢查映射是否將像素分散到較廣的灰階範圍。

3.4 影像處理前後比較

圖 6 的原圖整體偏暗。餅乾盒上的文字雖然可辨認，但餅乾表面、右下方玩偶與背景物品的細節較不明顯。等化後，包裝文字與餅乾紋理較容易辨識，玩偶的臉部、衣物及右側物品輪廓也更清楚，顯示部分暗部的可見度得到改善。

(a) 處理前：灰階原圖　　(b) 處理後：直方圖等化

图 6: 指定圖片 `dark.jpg` 的直方圖等化前後比較。

另一方面，餅乾盒左上方與餅乾表面的亮部也變得明亮，包裝與背景的顆粒感更明顯。所以本次結果雖有助於辨認暗部物品，並不代表亮部、雜訊與觀看感受都同時改善。直方圖等化沒有額外執行降噪，也不會辨識哪個區域是觀看者最關心的主體。

3.5 直方圖與強度映射分析

圖 7 顯示，原圖像素主要集中在低灰階區域，尤其約 0 至 120 的範圍。雖然仍有少量高灰階像素，但僅看最小值與最大值無法反映大部分像素偏暗的情況。等化後，像素分布延伸至較廣的灰階區間，與處理後較明亮、層次差異較大的觀察一致。

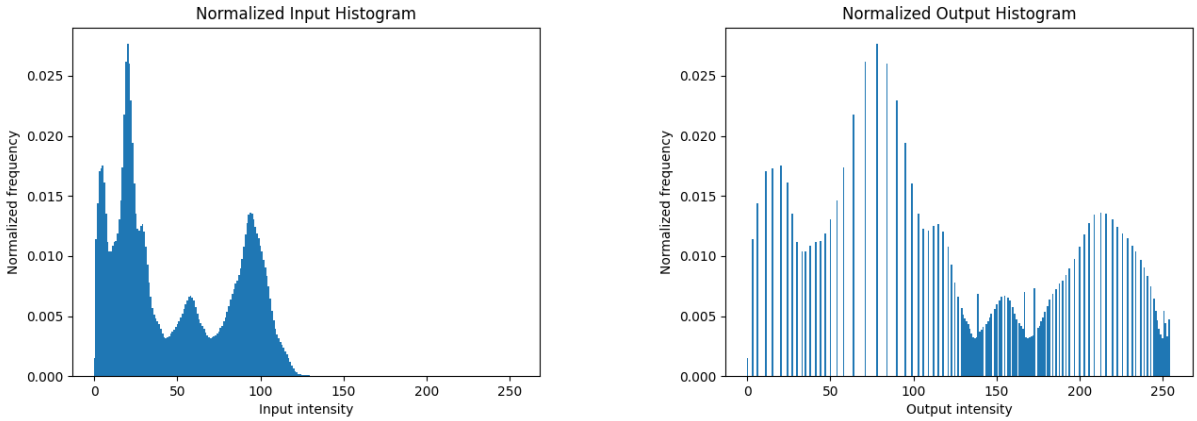

(a) 輸入正規化直方圖 (b) 輸出正規化直方圖

图 7: 直方圖等化前後的像素灰階比例分布。

輸出直方圖沒有完全平坦，且部分灰階之間存在空隙。這是離散影像中可能出現的現象：同一個輸入灰階的像素全部映射到同一個輸出值，無法任意拆分到不同灰階；有限灰階數與取整也會造成跳躍或合併。因此，不能只以「是否形成水平直線」判斷等化是否正確。

圖 8 的映射曲線在像素較集中的灰階區間上升較快，將這些輸入灰階對應到較廣的輸出範圍；在像素稀少的高灰階區間，曲線則接近平坦。這與 CDF 的定義相符，且整條曲線維持單調不減。

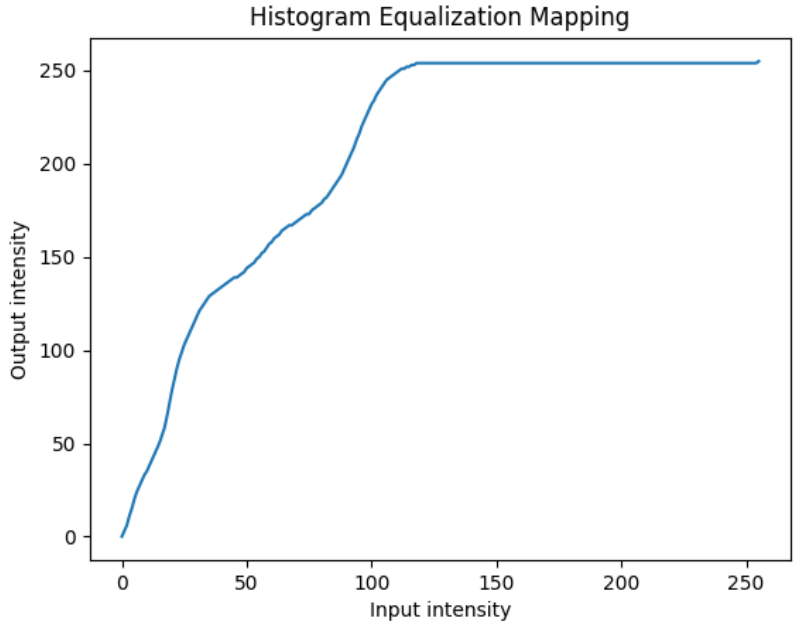

图 8: 輸入灰階至輸出灰階的 CDF 映射。

3.6 實測數據與結果檢查

表 4 的數值由儲存的完整尺寸 PNG 直接計算。平均灰階用於描述整體亮度；標準差用於描述像素灰階的整體分散程度，定義為

$$\sigma(J) = \sqrt{\frac{1}{HW}\sum_{y=0}^{H-1}\sum_{x=0}^{W-1}\left(J(x,y)-\mu(J)\right)^2}. \tag{7}$$

表 4: 指定圖片的直方圖等化前後統計。

指標	處理前	處理後
尺寸（寬 × 高）	4032×3024	4032×3024
資料型態	`uint8`	`uint8`
最小 / 最大灰階	$0/255$	$0/255$
平均灰階	48.68	128.53
灰階標準差	35.90	73.18
正規化直方圖總和	1.0	1.0

平均灰階提高，符合原圖偏暗、處理後整體變亮的觀察；標準差增加，表示灰階在整張圖中的分散程度提高。兩張圖雖然都具有 0 與 255 的極值，主要灰階分布卻有明顯差異，因此不能只用輸出是否涵蓋完整灰階範圍來評估效果。此外，標準差較大不能單獨證明局部細節或主觀品質較好，仍須配合前後圖片分析。

結果檢查包含：確認輸出尺寸與資料型態、核對兩張正規化直方圖總和皆為 1，以及檢查映射是否單調不減。另外，依原圖重新建立本程式的 CDF 映射後，逐像素對照 `equalized.png`，確認儲存結果與式 (6) 的實作一致。這些檢查支持程式與輸出的一致性，並不取代影像品質的視覺討論。

3.7 與 Gamma 轉換的比較及限制

Gamma 轉換依預先選定的參數改變像素強度，直方圖等化則依每張影像的灰階比例建立不同的映射。本次偏暗影像在等化後，文字、餅乾紋理與玩偶輪廓更容易觀看，但部分亮部也變得很亮，顆粒感較明顯。兩種方法都屬於全域逐像素強度轉換，不會根據物體或區域分別設定觀看目標，也無法恢復原圖中已經消失的資訊。因此，評估時應同時考慮亮度、灰階分布、細節可見度與副作用，不能只以整體變亮判定成功。

實作者：待填。　**審查者：**待填。
審查意見：待實際檢查後填寫。

4 空間濾波：牙齒與頭骨影像比較

4.1 實驗目的與處理流程

此題以 `pxhere-mouth.jpeg` 的牙齒與下顎影像，以及 `wellcome-skull.png` 的頭骨影像測試空間濾波增強。本節依組員整理的比較觀察，分別討論 Laplacian 與 Sobel 梯度、Laplacian 與 Mask，以及原圖、直接銳化與 Mask 銳化三組差異，並以實際輸出圖說明細節增強與細碎反應之間的取捨。

實驗在 `hw1` 資料夾執行下列指令。程式先檢查指定的 3×3 卷積案例，再依序處理兩張圖片，結果分別儲存於 `results/medical/mouth` 與 `results/medical/skull`。

Listing 6: 醫學影像增強實驗的執行指令

```
python medical_experiments.py
```

表 5 列出下列比較所使用的處理階段。兩張影像採用相同設定：Laplacian 為中央係數 8、周圍八個係數 -1 的 3×3 核心；Sobel 使用水平與垂直兩個 3×3 核心，再計算梯度大小；Box filter 的半徑為 2，即 5×5，各係數為 $1/25$。

表 5: 醫學影像比較所用的輸出階段。

輸出檔名	處理內容
`0-gray.png`	灰階原圖 I。
`1-laplacian.png`	Laplacian 細節影像 L。
`2-gradient.png`	Sobel 梯度大小影像。
`3-smoothed-gradient.png`	經 5×5 Box filter 平滑的梯度影像 S。
`4-sharpened.png`	將 L 加回原圖，得到直接銳化結果。
`5-mask.png`	將 L 與 S 正規化後逐像素相乘，得到 Mask。
`6-denoised_sharpened.png`	將 Mask 加回原圖，得到調整增強量後的結果。

Laplacian 與梯度影像依程式設定截斷至 $[0, 255]$，並轉為八位元影像；因此，下列觀察對應的是程式輸出的可視化結果，Laplacian 的負反應未保留在輸出 PNG 中。Mask 的乘法在正規化後進行，可視為使用平滑梯度調整各位置的 Laplacian 增強量。梯度較弱的位置通常加入較少細節，梯度較強的位置則保留較多反應。為觀察濾波與銳化本身的效果，下列三組比較皆使用最後 Gamma 提亮之前的影像。

4.2 六個運算函式的 TODO 實作與說明

以下六個函式取自 `spatial_operations.py`，省略原始註解與空行，保留實際運算、資料型態轉換及回傳步驟。輸入影像皆為二維灰階影像；除卷積測試使用浮點矩陣外，本實驗傳入各濾波與影像乘加函式的像素值均位於 $[0, 255]$。除以 255 是依固定灰階範圍縮放，並非依每張圖片的最

大值與最小值重新拉伸。運算前轉為浮點數可保留負值與小數，避免直接以 `uint8` 做乘加時發生溢位。

4.2.1 `convolution`：補零與二維卷積

Listing 7: 自行實作補零與兩層迴圈卷積

```
def convolution(input_image, kernel):
    output_image = input_image.copy()
    height, width = input_image.shape
    size = kernel.shape[0]
    if kernel.shape != (size, size) or size % 2 == 0:
        raise ValueError('The kernel must be a square with odd side length.')
    radius = size // 2
    padded_image = np.pad(input_image.astype(float), radius, mode='constant')
    output_image = np.zeros((height, width), dtype=float)
    flipped_kernel = kernel[::-1, ::-1]
    for y in range(height):
        for x in range(width):
            region = padded_image[y:y + size, x:x + size]
            output_image[y, x] = np.sum(region * flipped_kernel)
    return output_image
```

程式 7 先檢查核心是否為奇數邊長的方形矩陣，使中心位置與半徑 $r = \lfloor \texttt{size}/2 \rfloor$ 能明確定義。`np.pad` 在上、下、左、右各補 r 個零，因此原圖邊界也能取出完整視窗，輸出仍維持原本的高與寬。`kernel[::-1, ::-1]` 將核心的列與欄順序反轉，相當於旋轉 180 度，符合本題採用的數學卷積定義。兩層 `for` 分別遍歷列 y 與欄 x，切出局部區塊後，以 NumPy 做逐項乘法與加總，未呼叫第三方卷積 API。若核心邊長為 $2r+1$，實際計算式為

$$O[y,x] = \sum_{i=0}^{2r} \sum_{j=0}^{2r} I_{\text{pad}}[y+i, x+j]\, K[2r-i, 2r-j]. \tag{8}$$

輸出採浮點數且未截斷，可保留卷積結果的小數與正負號；是否縮放、截斷或轉成八位元影像，交由呼叫它的濾波函式處理。

4.2.2 box_filter：局部平均與實際 Box 核心

Listing 8: 依半徑建立正規化 Box 核心並平滑影像

```
def box_filter(input_image, radius):
    output_image = input_image.copy().astype(float)
    output_image /= 255
    size = 2 * radius + 1
    kernel = np.ones((size, size), dtype=float) / (size * size)
    output_image = convolution(output_image, kernel)
    output_image *= 255
    output_image = output_image.astype(np.uint8)
    return output_image
```

程式 8 先將灰階值縮放到 $[0,1]$，再建立邊長為 $2r+1$ 的全一矩陣，並除以元素數量 $(2r+1)^2$，使所有係數總和為 1，卷積結果即為鄰域的平均值。本實驗對梯度影像使用半徑 $r=2$，實際核心為

$$K_{\mathrm{Box}} = \frac{1}{25}\begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}. \tag{9}$$

平滑梯度影像可將局部梯度反應取平均，作為後續 Mask 的權重。卷積後乘回 255，並轉為 `uint8`；非負小數部分會在轉型時截去。因為核心係數非負且總和為 1，對本實驗的輸入可維持灰階範圍。但邊界採補零，常數影像的邊緣也可能因納入外側零值而變暗。

4.2.3 laplacian_filter：二階差分與實際 Laplacian 核心

Listing 9: 使用中心為正的八鄰居 Laplacian 核心

```
def laplacian_filter(input_image):
    output_image = input_image.copy().astype(float)
    output_image /= 255
    kernel = np.array([[-1, -1, -1],
                       [-1,  8, -1],
                       [-1, -1, -1]], dtype=float)
    output_image = convolution(output_image, kernel)
    output_image *= 255
    output_image[output_image > 255] = 255
    output_image[output_image < 0] = 0
    output_image = output_image.astype(np.uint8)
    return output_image
```

程式 9 選擇中央係數為正的八鄰居核心，實際矩陣為

$$K_{\mathrm{L}} = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}. \tag{10}$$

其係數總和為 0，運算相當於「中心值的八倍減去八個鄰居的總和」，因此在不受補零邊界影響的常數區域反應為零，亮度快速變化處則有較大反應。以連續微分的符號來看，此中心為正的形式對應負的 Laplacian，故可依本題流程將其反應加回原圖以增強細節。本實作在乘回 255 後，將大於 255 的值設為 255、負值設為 0，再轉為 `uint8`。因此後續銳化使用的是經截斷的非負細節影像，並未保留完整的帶正負號二階差分；截斷會移除負反應與過大反應的幅值差異，也可能使加回後的亮部飽和。

4.2.4　`sobel_filter`：方向梯度、大小與實際 Sobel 核心

Listing 10: 以兩個 Sobel 核心計算梯度大小

```
def sobel_filter(input_image):
    output_image = input_image.copy().astype(float)
    output_image /= 255
    kernel_x = np.array([[-1, 0, 1],
                         [-2, 0, 2],
                         [-1, 0, 1]], dtype=float)
    kernel_y = np.array([[-1, -2, -1],
                         [ 0,  0,  0],
                         [ 1,  2,  1]], dtype=float)
    gx = convolution(output_image, kernel_x)
    gy = convolution(output_image, kernel_y)
    output_image = np.sqrt(gx ** 2 + gy ** 2)
    output_image *= 255
    output_image[output_image > 255] = 255
    output_image = output_image.astype(np.uint8)
    return output_image
```

程式 10 使用下列兩個核心，分別取得左右方向 x 與上下方向 y 的亮度變化：

$$K_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \qquad K_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}. \tag{11}$$

令正規化原圖為 $I_n = I/255$，先透過自行實作的卷積得到 $g_x = I_n * K_x$、$g_y = I_n * K_y$，再依

$$G(x,y) = \sqrt{g_x(x,y)^2 + g_y(x,y)^2} \tag{12}$$

合成梯度大小。`** 2` 表示逐元素平方，`np.sqrt` 為逐元素開根號，因此同時考慮兩方向的變化，且結果非負。由於卷積會旋轉核心，上列反對稱 Sobel 核心相較於不旋轉的互相關運算，方向反

應的符號會反轉，但平方後的梯度大小不受此符號差異影響。程式沒有另外將 Sobel 係數除以 8，而是直接將梯度大小乘回 255，把超過 255 的值截斷後轉為 `uint8`。因此輸出強度同時受核心倍率與飽和截斷影響，不能直接當作未截斷的梯度數值。

4.2.5 `image_product`：正規化後逐像素相乘

Listing 11: 將平滑梯度作為 Laplacian 細節的逐像素權重

```
def image_product(input_image_a, input_image_b):
    input_image_a = input_image_a.astype(float)
    input_image_b = input_image_b.astype(float)
    input_image_a /= 255
    input_image_b /= 255
    output_image = input_image_a.copy()
    output_image = input_image_a * input_image_b
    output_image *= 255
    output_image = output_image.astype(np.uint8)
    return output_image
```

程式 11 先將兩張同尺寸影像轉為浮點數並除以 255，再以 `*` 對相同位置的像素相乘，最後乘回 255 並轉為 `uint8`。這是逐元素乘法，不是矩陣乘法。對本實驗的 Laplacian 影像 L 與平滑梯度影像 S，轉型前的 Mask 計算為

$$M_{\text{float}}(x,y) = 255\left(\frac{L(x,y)}{255}\right)\left(\frac{S(x,y)}{255}\right) = \frac{L(x,y)S(x,y)}{255}. \tag{13}$$

由於 $S/255$ 位於 $[0,1]$，它可作為每個位置的增強權重：梯度較弱處減少加入的細節，較強處保留較多 Laplacian 反應。例如 $L = 128$、$S = 64$ 時，乘回灰階範圍後約為 32.13，轉型後為 32。兩個非負且不超過 1 的正規化值相乘仍位於 $[0,1]$，因此本流程不需額外截斷。

4.2.6 `image_sum`：逐像素相加與飽和截斷

Listing 12: 將細節影像加回原圖並限制最大灰階

```
def image_sum(input_image_a, input_image_b):
    input_image_a = input_image_a.astype(float)
    input_image_b = input_image_b.astype(float)
    input_image_a /= 255
    input_image_b /= 255
    output_image = input_image_a.copy()
    output_image = input_image_a + input_image_b
    output_image *= 255
    output_image[output_image > 255] = 255
    output_image = output_image.astype(np.uint8)
    return output_image
```

程式 12 先轉為浮點數並正規化，再以 `+` 做逐像素相加。兩個正規化像素相加後可能大於 1，因此乘回 255 後須將超過 255 的值截斷，避免轉為八位元整數時溢位；本實驗兩張輸入皆非負，故

沒有負值需要處理。不考慮浮點捨入與轉型截斷時，此運算等價於 $\min(255, A+B)$，實際整數結果則依上述浮點計算及 `uint8` 轉型取得。本流程以 `image_sum` 將原圖分別與 Laplacian 影像及 Mask 影像相加，產生直接銳化與 Mask 銳化影像。兩者都採加法，但 Mask 先透過平滑梯度減少部分細節增強量，因此與直接加入 Laplacian 的結果有所差異；兩者仍可能出現亮部飽和。

4.3 補零示意與指定卷積測試

4.3.1 指定 3×3 卷積測試與輸出數值

為檢查程式 7 的補零、核心旋轉與邊界計算，`medical_experiments.py` 使用作業指定的輸入矩陣與非對稱核心：

$$I_{\text{test}} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}, \qquad K_{\text{test}} = \frac{1}{7}\begin{bmatrix} -1 & 1 & 1 \\ -1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}. \tag{14}$$

此時 $r = 1$，影像四周各補一個零，得到

$$I_{\text{pad}} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 2 & 3 & 0 \\ 0 & 4 & 5 & 6 & 0 \\ 0 & 7 & 8 & 9 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}. \tag{15}$$

依數學卷積定義旋轉核心後，實測結果為

$$O_{\text{test}} = \frac{1}{7}\begin{bmatrix} -2 & 3 & 16 \\ 1 & 15 & 33 \\ 8 & 21 & 28 \end{bmatrix}. \tag{16}$$

儲存在 `convolution-test.csv` 的結果保留小數點後八位，數值如下：

$$O_{\text{CSV}} = \begin{bmatrix} -0.28571429 & 0.42857143 & 2.28571429 \\ 0.14285714 & 2.14285714 & 4.71428571 \\ 1.14285714 & 3.00000000 & 4.00000000 \end{bmatrix}. \tag{17}$$

此矩陣為式 16 的小數表示，CSV 與精確分數矩陣的最大絕對差約為 4.29×10^{-9}，來自存檔時的小數位數限制。例如左上角視窗使用旋轉後的核心，得到 $(1 - 2 + 4 - 5)/7 = -2/7$，顯示卷積函式保留負值，而非在此階段歸零。測試程式以 `np.testing.assert_allclose` 與預期矩陣比較，設定絕對容許誤差為 10^{-12}，並輸出 `results/medical/convolution-test.csv` 與圖 9。此非對稱核心也能區分「有旋轉核心的卷積」與「不旋轉核心的互相關」。

Input

1.0000	2.0000	3.0000
4.0000	5.0000	6.0000
7.0000	8.0000	9.0000

Kernel

-0.1429	0.1429	0.1429
-0.1429	0.1429	0.1429
0.1429	0.1429	0.1429

Zero-padded input

0.0000	0.0000	0.0000	0.0000	0.0000
0.0000	1.0000	2.0000	3.0000	0.0000
0.0000	4.0000	5.0000	6.0000	0.0000
0.0000	7.0000	8.0000	9.0000	0.0000
0.0000	0.0000	0.0000	0.0000	0.0000

Convolution output

-0.2857	0.4286	2.2857
0.1429	2.1429	4.7143
1.1429	3.0000	4.0000

图 9: 指定卷積測試的輸入、核心、補零矩陣與輸出數值；圖中數值顯示至小數第四位，精確結果如式 16。

實際影像同樣採補零：Laplacian 與 Sobel 的 3×3 核心每側補 1 個像素，Box 的 5×5 核心每側補 2 個像素。補零影像是運算用的中間陣列，最終濾波輸出的高寬仍與輸入相同。

4.3.2 實際影像的補零圖片與驗證

兩組補零素材位於 `results/medical` 下的 `mouth` 與 `skull` 資料夾。圖 10 與圖 11 分別展示兩個案例的 `padded.png`（補零全圖）與 `padding-detail.png`（左上角放大圖）。兩組素材皆示範半徑 $r = 1$ 的補零，對應 3×3 核心：原影像的上、下、左、右各新增一個像素寬的零值邊框，高寬由 $H \times W$ 變為 $(H + 2) \times (W + 2)$。表 6 列出直接讀取影像檔案後核對的尺寸與像素結果。

表 6: 實際補零影像的檢查結果；尺寸順序為高 × 寬，單位為像素。

案例	原灰階影像	每側補一個零後	四側新增像素值
牙齒與下顎	150×336	152×338	全為 0
頭骨	900×1100	902×1102	全為 0

除尺寸外，也逐像素確認補零圖的內部區域 `padded[1:-1, 1:-1]` 與原灰階圖完全一致，且第一列、最後一列、第一欄及最後一欄皆為 0。因此新增的只有零值邊框，影像內部並未因補零而改變。左上角放大圖中，座標 0 的列與欄所形成的黑色帶即為新增邊框；影像本身原有的亮色邊緣仍保留在框內。

(a) 補零全圖：152×338

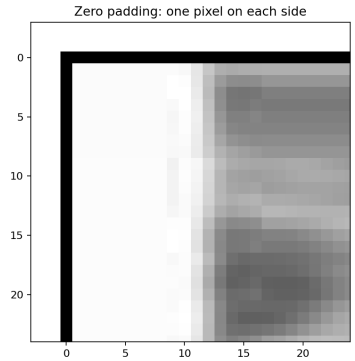

(b) 左上角放大：顯示新增零值邊框

图 10: 牙齒與下顎影像每側補一個零值像素後的全圖與局部放大。

(a) 補零全圖：902×1102

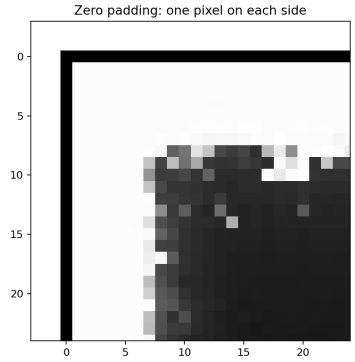

(b) 左上角放大：顯示新增零值邊框

图 11: 頭骨影像每側補一個零值像素後的全圖與局部放大。

若使用半徑 $r = 2$ 的 5×5 Box 核心，依同一規則每側補兩個零值像素，運算陣列的尺寸為 $(H + 4) \times (W + 4)$。無論使用哪一個半徑，卷積函式都只輸出原影像的 $H \times W$ 個位置，因此不能將補零後的中間陣列尺寸誤認為濾波結果尺寸。補零也假設影像外側亮度為零，靠近邊界的濾波反應可能因此不同於影像內部。

4.4 牙齒與下顎影像

4.4.1 Laplacian 與 Gradient 比較

如圖 12，Laplacian 呈現較細碎的線條與點狀紋理，牙齒及下顎周圍的反應較零散。Gradient 中的牙齒邊界與下顎輪廓則較明亮、粗且連續，主要結構更容易辨認。這與兩者的運算特性一致：Laplacian 使用二階差分，對局部快速變化較敏感；Sobel 梯度大小則整合兩個方向的一階變化，使主要邊界較突出。圖像亮暗也受到核心係數、幅值與截斷方式影響，不能只以線條較亮判斷方法優劣。

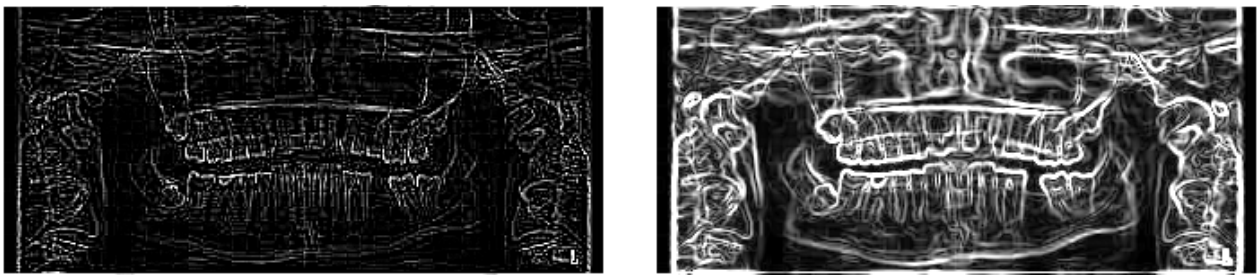

(a) Laplacian (b) Sobel Gradient

图 12: 牙齒與下顎影像的 Laplacian 與梯度大小比較。

4.4.2 Laplacian 與 Mask 比較

如圖 13，相較於 Laplacian，Mask 整體較暗，牙齒與下顎周圍的部分細碎反應減弱，主要輪廓仍有保留。原因是平滑梯度作為逐像素權重，使梯度較弱處的 Laplacian 反應受到抑制。Mask 變暗是乘法調整增強量的結果；同時也可能削弱有用的微小紋理，所以需要連同主要輪廓與細節的保留程度一起評估。

(a) Laplacian (b) Mask

图 13: 牙齒與下顎影像的 Laplacian 與 Mask 比較。

4.4.3 原圖、Sharpened 與 Denoised Sharpened 比較

如圖 14，相較於原圖，直接銳化的 Sharpened 在牙齒周圍及下顎輪廓的邊緣更明顯，但也增加了細碎點狀反應、顆粒感與過強的亮線。將 Mask 加回原圖的 Denoised Sharpened，則減弱了這些額外反應，仍保留主要牙齒與下顎輪廓，整體較接近原圖。不過，牙齒內部細微紋理的增強程度也較小，顯示抑制細碎反應與強調微小細節之間存在取捨。

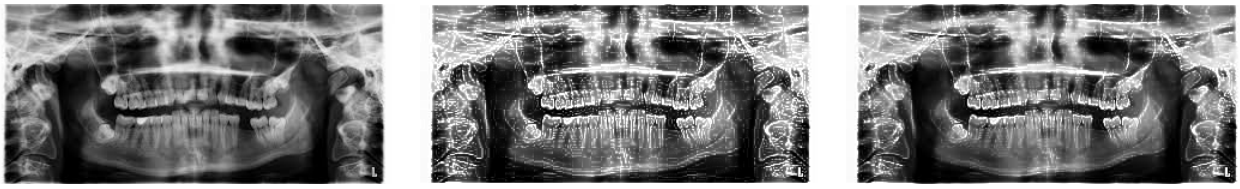

(a) 灰階原圖 (b) 直接銳化 (c) Mask 加回原圖

图 14: 牙齒與下顎影像的原圖及兩種銳化結果比較。

4.5 頭骨影像

4.5.1 Laplacian 與 Gradient 比較

如圖 15，Laplacian 整體較暗，呈現頭骨內部的細碎紋理與較細的邊緣。Gradient 的頭骨外框、眼眶及頸椎輪廓則較明亮、粗且連續，主要結構更容易辨認。這與牙齒案例的趨勢相同：兩種運算對細碎變化與主要輪廓的呈現方式不同，需依想觀察的細節選擇合適的結果。

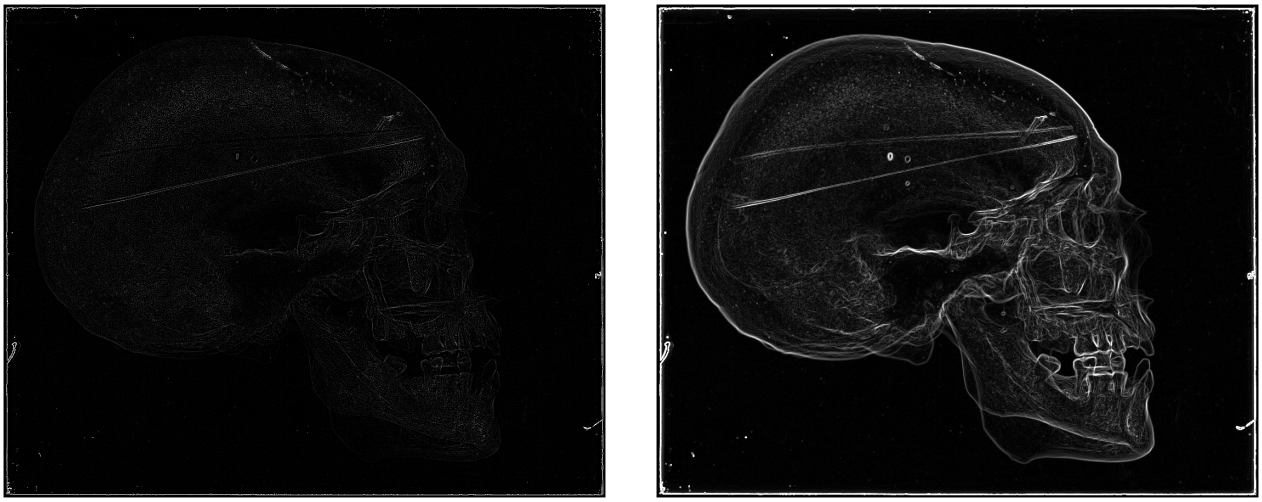

(a) Laplacian (b) Sobel Gradient

图 15: 頭骨影像的 Laplacian 與梯度大小比較。

4.5.2 Laplacian 與 Mask 比較

如圖 16，相較於 Laplacian，Mask 在頭骨內部的細碎反應較不明顯，整體更暗，但頭骨外框與部分眼眶輪廓仍有保留。這顯示乘上平滑梯度後，增強量較集中於梯度較明顯的位置。另一方面，頭骨內部部分原本就較弱的細節也受到抑制，因此不能僅以 Mask 的背景較暗，就認為所有細節都有改善。

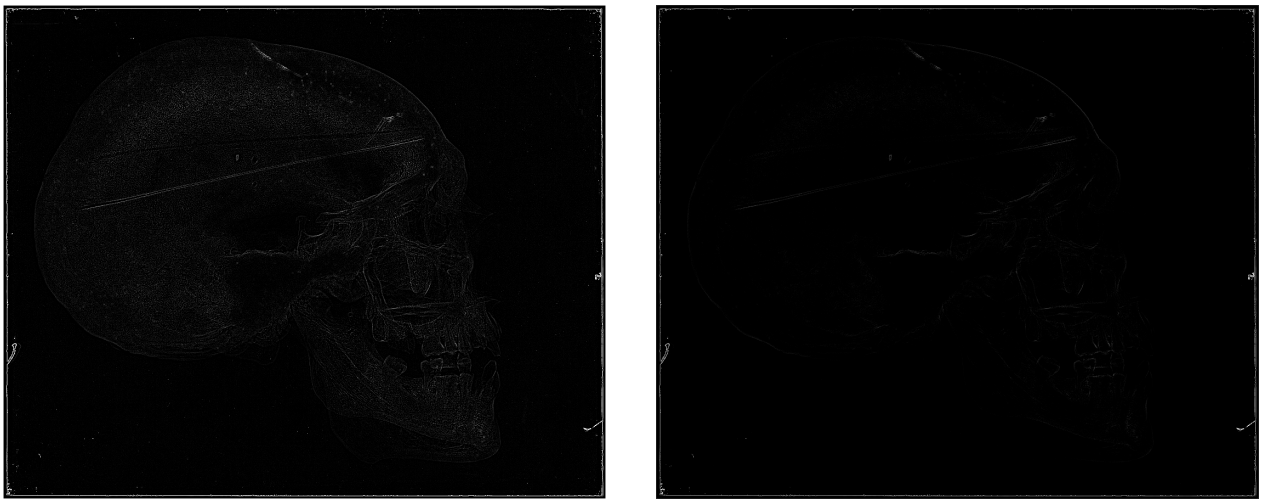

(a) Laplacian (b) Mask

图 16: 頭骨影像的 Laplacian 與 Mask 比較。

4.5.3 原圖、Sharpened 與 Denoised Sharpened 比較

如圖 17，相較於原圖，直接銳化的 Sharpened 使頭骨外框與眼眶邊緣更明顯，但頭骨上半部也出現較強的顆粒感與細碎紋理。Denoised Sharpened 減弱了這些增強反應，保留主要輪廓，整體較接近原圖；相對地，內部細節的增強程度也較小。因此，使用 Mask 的效果可描述為降低直接銳化的部分細碎增強，而細節保留的程度仍需配合影像內容評估。

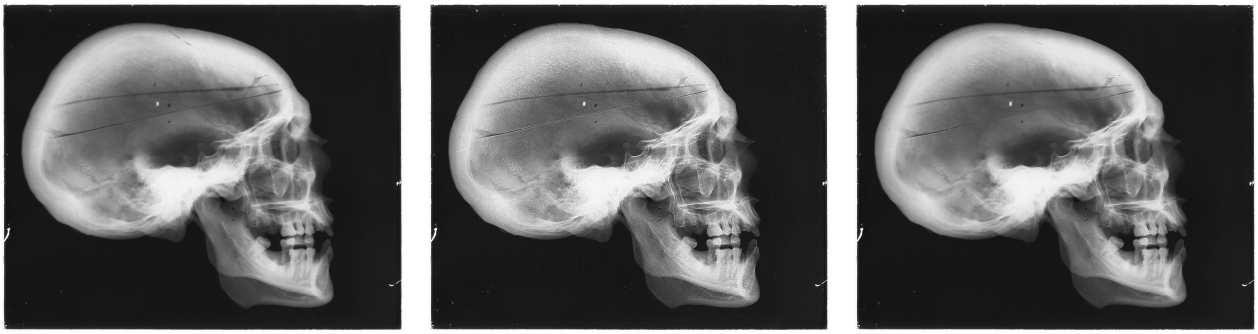

(a) 灰階原圖 (b) 直接銳化 (c) Mask 加回原圖

图 17: 頭骨影像的原圖及兩種銳化結果比較。

4.6 兩個案例的共同觀察與限制

兩個案例皆呈現相近趨勢：Laplacian 的細碎紋理與點狀反應較多，Sobel Gradient 的主要輪廓較明顯；乘上平滑梯度後，Mask 的弱反應受到抑制。將 Laplacian 直接加回原圖能強化邊緣，但也較容易增加顆粒與過強亮線；改用 Mask 後，主要輪廓仍有保留，整體較接近原圖，但微小細節的增強量也較少。

程式將 Mask 銳化結果命名為 Denoised Sharpened。本次圖片比較支持的是「相較於直接銳化，部分細碎增強反應減弱」，尚未使用已知雜訊或無雜訊參考影像計算定量指標，因此降噪程度仍須額外驗證。這些觀察也說明，銳化評估應同時考慮主要輪廓、微小紋理與顆粒感，不能只依邊緣是否更亮判斷影像處理效果。

比較整理者：待填。 **實作者：**待填。
審查者：待填。 **審查意見：**待實際檢查後填寫。

5 卷積神經網路：自製模型與 PyTorch 比較

5.1 實驗目的、資料與測試設定

此題以 torch tensor 運算自行實作卷積、最大池化、Sigmoid 與前向傳遞，再使用相同架構及參數的 PyTorch 模型作為對照，檢查兩者的輸出一致性。本次實驗使用隨機初始化權重，觀察的是前向計算的數值結果；這些輸出尚未透過訓練建立分類意義。

測試程式為 `test_cnn.py`，模型定義位於 `cnn.py`。在 `hw1` 資料夾執行下列指令，即可產生四組輸出、比較圖與摘要：

Listing 13: CNN 比較實驗的執行指令

```
python test_cnn.py
```

表 7 列出本次案例。三張自製影像由程式繪製條紋、矩形與圓形，測試不同輸入大小；照片案例讀取 `gamma_normal.jpg`，以面積插值縮放為 128×128。輸入尺寸及輸出數量均落在題目指定範圍內。

表 7: CNN 測試案例與輸出設定。

案例	輸入影像 (高、寬、通道)	輸出向量	Flatten 長度
`drawn-120`	$(120, 120, 3)$	3×1	7200
`drawn-160`	$(160, 160, 3)$	5×1	12800
`drawn-240`	$(240, 240, 3)$	10×1	28800
`photo-128`	$(128, 128, 3)$	5×1	8192

每組實驗設定 `torch.manual_seed(7)`，輸入與模型參數皆使用 `float64`，在 CPU 上執行，並設定一個 torch 運算執行緒。四組模型依輸入與輸出大小分別建立；同一組內的兩個模型才逐項複製參數並比較。

Listing 14: 讀取或建立測試圖片，轉為模型輸入

```
if name == 'photo-128':
    image = read_image(base / 'images' / 'gamma_normal.jpg')
    image = cv2.resize(image, (size, size), interpolation=cv2.INTER_AREA)
else:
    image = make_test_image(size)
height, width, channels = image.shape
rgb = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)
x = torch.from_numpy(rgb.astype(np.float64) / 255.0)
x = x.permute(2, 0, 1).unsqueeze(0).contiguous()
```

程式 14 將 OpenCV 影像由 BGR 轉為 RGB，把像素正規化至 $[0, 1]$。`permute` 將 (H, W, C) 改排為 (C, H, W)，`unsqueeze` 加入 batch 維度，得到 (B, C, H, W)，其中 $B = 1$。`contiguous` 使重排後的 tensor 具有連續的記憶體排列。

5.2　網路架構與各層尺寸

兩個模型皆使用兩組「卷積、Sigmoid、Max Pooling」，再接 Flatten、全連接層及 Sigmoid。第一、第二個卷積層的輸出通道數分別為 4 與 8；核心大小均為 3×3，stride 為 1、padding 為 1，因此卷積前後高寬相同。最大池化使用 2×2 視窗及 stride 2，每次使高寬減半。最後的特徵長度為

$$F = 8\left\lfloor \frac{H}{4} \right\rfloor \left\lfloor \frac{W}{4} \right\rfloor . \tag{18}$$

全連接層的權重形狀為 (N, F)，其中 N 是該案例的輸出神經元數量。

表 8: 四組案例的各層輸出尺寸；影像特徵依 (B, C, H, W) 排列。

階段	`drawn-120`	`drawn-160`	`drawn-240`	`photo-128`
Input	$(1,3,120,120)$	$(1,3,160,160)$	$(1,3,240,240)$	$(1,3,128,128)$
Conv1 + Sigmoid	$(1,4,120,120)$	$(1,4,160,160)$	$(1,4,240,240)$	$(1,4,128,128)$
Pool1	$(1,4,60,60)$	$(1,4,80,80)$	$(1,4,120,120)$	$(1,4,64,64)$
Conv2 + Sigmoid	$(1,8,60,60)$	$(1,8,80,80)$	$(1,8,120,120)$	$(1,8,64,64)$
Pool2	$(1,8,30,30)$	$(1,8,40,40)$	$(1,8,60,60)$	$(1,8,32,32)$
Flatten	$(1,7200)$	$(1,12800)$	$(1,28800)$	$(1,8192)$
FC + Sigmoid	$(1,3)$	$(1,5)$	$(1,10)$	$(1,5)$

模型內部保留 batch 維度，所以最後的 tensor 為 $(1, N)$。存檔時，程式先以 `reshape(-1,1)` 轉為 $N\times 1$ 欄向量，再分別輸出兩個模型的結果。表 8 的尺寸取自各組實際輸出的摘要檔。

5.3　自製模型的程式實作

5.3.1　參數初始化

Listing 15: 自製 CNN 的參數初始化

```
height, width, channels = input_size
output_count, _ = output_size
self.flatten_size = 8 * (height // 4) * (width // 4)
self.weight1 = torch.randn(4, channels, 3, 3, dtype=torch.float64) * 0.1
self.bias1 = torch.randn(4, dtype=torch.float64) * 0.1
self.weight2 = torch.randn(8, 4, 3, 3, dtype=torch.float64) * 0.1
self.bias2 = torch.randn(8, dtype=torch.float64) * 0.1
self.fc_weight = torch.randn(output_count, self.flatten_size,
                             dtype=torch.float64) / math.sqrt(self.flatten_size)
self.fc_bias = torch.randn(output_count, dtype=torch.float64) * 0.1
self.sigmoid = SigmoidActivation()
```

程式 15 為建構函式的核心參數設定，省略形狀紀錄等輔助程式。卷積權重依「輸出通道、輸入通道、核心高、核心寬」排列，每個輸出通道另有一個 bias。卷積權重乘以 0.1，全連接權重依

特徵長度縮放，目的在控制初始加權和的尺度，降低 Sigmoid 大量落在接近 0 或 1 區域的機會。全連接層依式 (18) 的特徵數建立，確保各案例尺寸可銜接。

5.3.2 自製卷積

Listing 16: 以 torch tensor 自行實作卷積

```
def convolution(self, x, weight, bias, padding=1, stride=1):
    batch, channels, height, width = x.shape
    out_channels, _, kernel_h, kernel_w = weight.shape
    padded = x.new_zeros(batch, channels, height + 2 * padding,
                         width + 2 * padding)
    padded[:, :, padding:padding + height, padding:padding + width] = x
    out_h = (height + 2 * padding - kernel_h) // stride + 1
    out_w = (width + 2 * padding - kernel_w) // stride + 1
    out = x.new_zeros(batch, out_channels, out_h, out_w)
    for y in range(out_h):
        for col in range(out_w):
            region = padded[:, :, y * stride:y * stride + kernel_h,
                            col * stride:col * stride + kernel_w]
            products = region.unsqueeze(1) * weight.unsqueeze(0)
            out[:, :, y, col] = products.sum(dim=(2, 3, 4)) + bias
    return out
```

程式 16 先建立補零 tensor，再將原輸入放入中央區域。兩層迴圈逐位置取出局部區塊，使用 broadcasting 同時計算各輸出通道，對輸入通道與核心高寬加總後加入 bias。batch 與輸出通道維度保持分開，輸出高寬則由核心、padding 與 stride 計算。此函式使用 tensor 基本運算，自製模型未直接呼叫第三方卷積 API。

本 CNN 的核心直接與區塊逐項相乘，採用與對照模型相同的互相關規則，核心不旋轉。前一節的空間濾波函式採數學卷積定義而先旋轉核心 180 度；這兩種介面各自依其比較目標定義，實驗時必須確認所採用的規則。

5.3.3 自製最大池化與 Sigmoid

Listing 17: 自製最大池化

```
def maxpool(self, x, pool_size, pool_stride):
    batch, channels, height, width = x.shape
    out_h = (height - pool_size) // pool_stride + 1
    out_w = (width - pool_size) // pool_stride + 1
    out = x.new_zeros(batch, channels, out_h, out_w)
    for y in range(out_h):
        for col in range(out_w):
            region = x[:, :, y * pool_stride:y * pool_stride + pool_size,
                       col * pool_stride:col * pool_stride + pool_size]
            out[:, :, y, col] = region.amax(dim=(2, 3))
```

```
    return out
```

程式 17 依池化視窗與 stride 取出區塊，`amax(dim=(2,3))` 僅在空間維度取最大值，保留各 batch 與通道的獨立性。本次視窗與 stride 都為 2，因此使用不重疊區塊，使高寬縮小。自製模型使用此函式完成池化，未直接呼叫第三方 pooling API。

Listing 18: 自行實作 Sigmoid

```
class SigmoidActivation:
    def activate(self, z):
        return 1.0 / (1.0 + torch.exp(-z))
```

程式 18 將公式 $\sigma(z) = 1/(1 + e^{-z})$ 逐元素套用至 tensor。本實驗在兩個卷積層及全連接層之後使用此函式。輸出位於 0 與 1 之間，但其數值意義仍取決於模型的設定與訓練目的。

5.3.4 自製前向傳遞

Listing 19: 自製 CNN 的前向傳遞

```
def forward(self, x):
    out = self.convolution(x, self.weight1, self.bias1)
    out = self.sigmoid.activate(out)
    out = self.maxpool(out, 2, 2)
    out = self.convolution(out, self.weight2, self.bias2)
    out = self.sigmoid.activate(out)
    out = self.maxpool(out, 2, 2)
    out = out.reshape(out.shape[0], -1)
    out = out @ self.fc_weight.T + self.fc_bias
    return self.sigmoid.activate(out)
```

程式 19 依架構順序串接各操作。`reshape` 保留 batch，將其餘特徵展平；全連接層以矩陣乘法及 bias 計算加權和，最後再經過 Sigmoid。程式片段省略了原程式中不影響結果的暫存變數賦值，運算順序相同。

5.4 PyTorch 對照模型與相同權重比較

Listing 20: PyTorch 對照模型

```
class ThirdPartyCNN(nn.Module):
    def __init__(self, input_size, output_size):
        super().__init__()
        height, width, channels = input_size
        output_count, _ = output_size
        self.conv1 = nn.Conv2d(channels, 4, 3, padding=1)
        self.conv2 = nn.Conv2d(4, 8, 3, padding=1)
        self.pool = nn.MaxPool2d(2, stride=2)
        self.flatten_size = 8 * (height // 4) * (width // 4)
```

```
        self.fc = nn.Linear(self.flatten_size, output_count)
        self.sigmoid = nn.Sigmoid()
        self.double()

    def forward(self, x):
        out = self.pool(self.sigmoid(self.conv1(x)))
        out = self.pool(self.sigmoid(self.conv2(out)))
        out = out.reshape(out.shape[0], -1)
        return self.sigmoid(self.fc(out))
```

程式 20 使用 PyTorch API 建立相同的卷積、池化與全連接架構，並以 `double()` 將浮點參數轉為雙精度，以配合輸入及自製模型。前向傳遞中相鄰的呼叫以巢狀方式呈現，順序與原程式相同。相同形狀只保證模型可銜接；為比較數值，還須將權重與 bias 完整複製。

Listing 21: 建立模型、複製權重並計算兩組輸出

```
torch.manual_seed(7)
custom = ConvolutionalNeuralNetwork((height, width, channels), output_size)
with torch.no_grad():
    custom_out = custom.forward(x)

third = ThirdPartyCNN((height, width, channels), output_size)
third.eval()
with torch.no_grad():
    third.conv1.weight.copy_(custom.weight1)
    third.conv1.bias.copy_(custom.bias1)
    third.conv2.weight.copy_(custom.weight2)
    third.conv2.bias.copy_(custom.bias2)
    third.fc.weight.copy_(custom.fc_weight)
    third.fc.bias.copy_(custom.fc_bias)
    third_out = third(x)
```

程式 21 將兩個卷積層及全連接層的六組參數逐項複製，確保同組實驗使用相同輸入與相同參數。固定隨機種子有助於重現初始化結果，而這裡實際的參數一致性由 `copy_` 保證。`no_grad` 關閉梯度紀錄，適用於本次前向比較；`eval` 將對照模型設定為評估模式。

5.5 誤差定義與數值檢查

對兩個模型的 N 個輸出 a_i 與 b_i，本實驗計算

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(a_i - b_i)^2, \tag{19}$$

$$E_{\max} = \max_{1\le i\le N} |a_i - b_i|. \tag{20}$$

MSE 用於描述平均平方差，最大絕對誤差則補充最不一致的一個輸出位置。

Listing 22: MSE 與輸出一致性檢查

```
def compare_outputs(custom, third):
    return torch.mean((custom - third) ** 2).item()

assert custom_out.shape == (1, output_count)
torch.testing.assert_close(custom_out, third_out, rtol=1e-9, atol=1e-10)
mse = compare_outputs(custom_out, third_out)
max_error = torch.max(torch.abs(custom_out - third_out)).item()
```

程式 22 對逐元素差值平方後取平均，`item()` 將單一數值轉為 Python 數字。程式另外檢查輸出形狀，並依指定的相對與絕對容許誤差比較兩個 tensor。四組測試均通過這些檢查。

表 9: 由本次摘要檔讀取的 CNN 輸出誤差。

案例	MSE	最大絕對誤差
`drawn-120`	0	0
`drawn-160`	1.232595×10^{-32}	2.220446×10^{-16}
`drawn-240`	9.552613×10^{-33}	2.220446×10^{-16}
`photo-128`	7.395571×10^{-33}	1.110223×10^{-16}

5.6 測試圖片與輸出曲線比較

圖 18 使用最小的 120×120 測試圖，輸出三個數值。兩條曲線重疊，此次完整精度的輸出比較也得到 MSE 與最大絕對誤差皆為零。

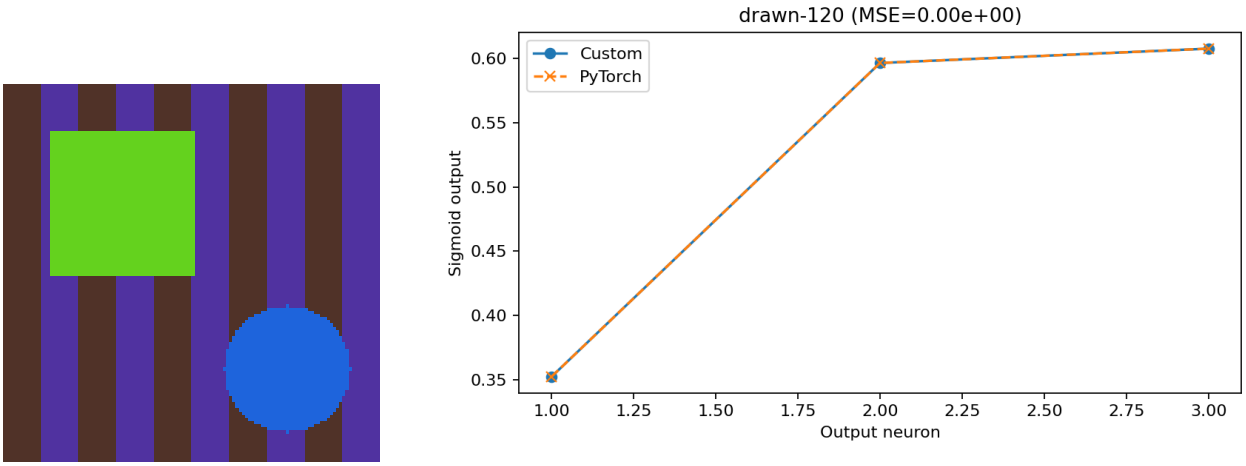

(a) 輸入影像　　(b) 兩個模型的輸出

图 18: 自製幾何影像 `drawn-120`，輸出向量為 3×1。

圖 19 使用 160×160 影像，輸出五個數值。兩條曲線在圖上仍重疊，完整精度下最大差異約為 2.22×10^{-16}，因此一般圖表尺度無法辨認此差異。

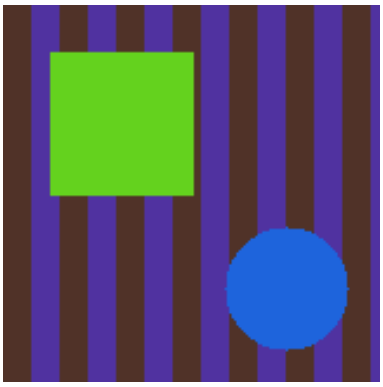

(a) 輸入影像

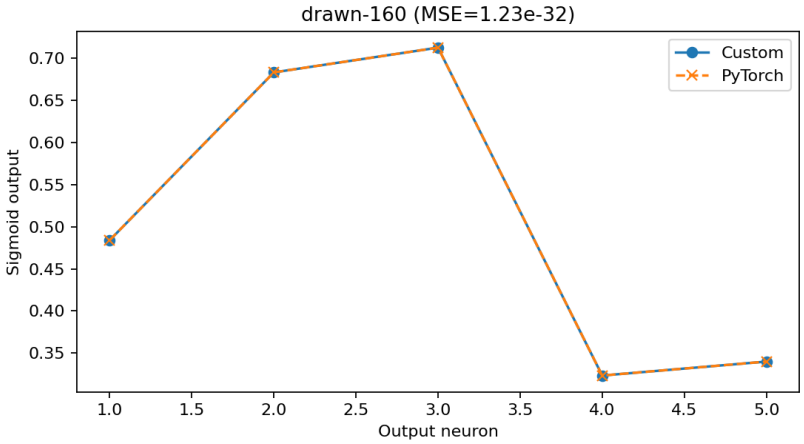

(b) 兩個模型的輸出

图 19: 自製幾何影像 `drawn-160`，輸出向量為 5×1。

圖 20 測試題目輸入大小的上限，輸出十個數值。Flatten 長度增加至 28800，兩個模型在較大的特徵尺寸下仍通過一致性檢查，本組 MSE 約為 9.55×10^{-33}。

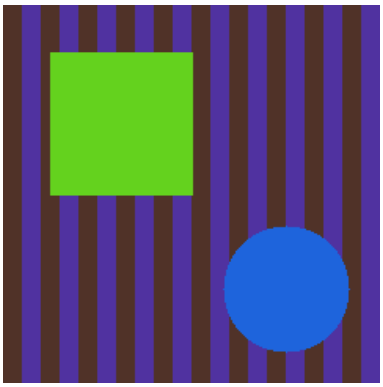

(a) 輸入影像

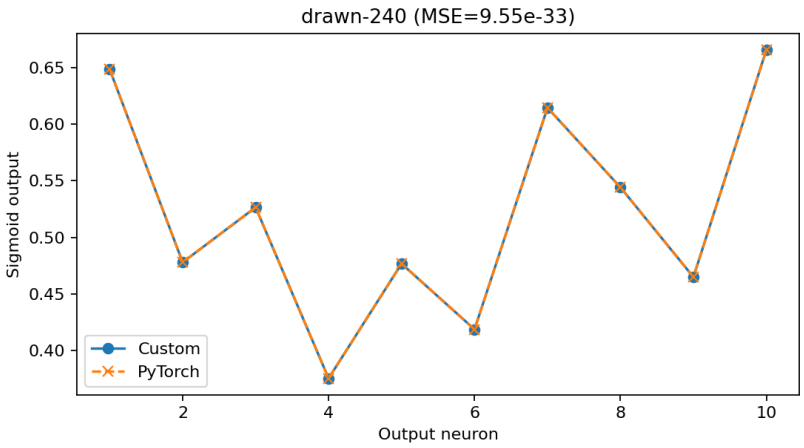

(b) 兩個模型的輸出

图 20: 自製幾何影像 `drawn-240`，輸出向量為 10×1。

圖 21 改用實際照片，輸出五個數值。兩個模型的曲線仍接近重疊，MSE 約為 7.40×10^{-33}。這組案例顯示在本次照片輸入條件下，自製運算與對照模型也得到接近一致的結果。

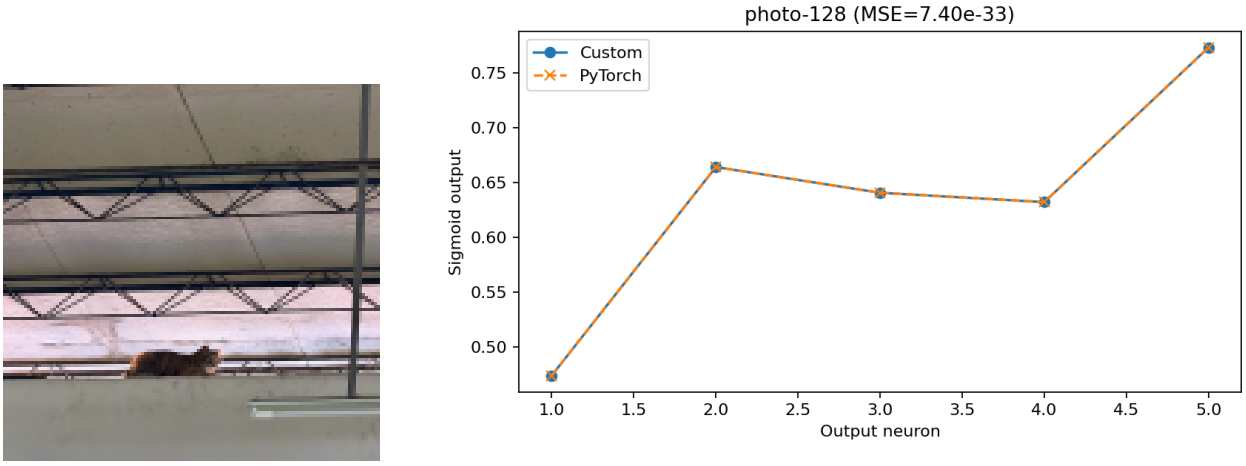

(a) 輸入影像　　(b) 兩個模型的輸出

图 21: 實際照片 `photo-128`，輸出向量為 5×1。

表 10 列出照片案例儲存在 CSV 中的輸出，供數字對照。數值保留至小數點後十五位；式 (19) 則使用格式化之前的原始 `float64` tensor 計算。因此，表格中的末位差異不應直接當作完整精度下的實際誤差。

表 10: `photo-128` 的輸出數值（依 CSV 的十五位小數表示）。

輸出編號	自製模型	PyTorch 模型
1	0.473947784342271	0.473947784342271
2	0.664193823150563	0.664193823150563
3	0.640714209828927	0.640714209828927
4	0.632176596193099	0.632176596193099
5	0.773140255311716	0.773140255311715

5.7　結果討論與驗證範圍

四組實驗涵蓋不同輸入尺寸、不同輸出數量及兩類影像內容，MSE 為零或約 10^{-32}，最大絕對差異約 10^{-16}。結果支持本次架構與測試條件下，自製前向計算與 PyTorch 對照模型的數值一致性。極小的非零差異與雙精度浮點運算中不同加總順序的捨入差異相容，不能將圖上重疊直接解讀為每個案例皆逐位元相同。

本次驗證的重點包括：正確的輸入維度、卷積與池化規則、Flatten 長度、全連接運算，以及參數複製。目前實驗使用 CPU、batch 1、三通道方形影像與固定的網路架構；對其他 batch、非方形輸入或不同核心設定的適用性，仍需另外測試。權重由隨機數初始化，輸出曲線用來比較兩種計算流程，其數值大小尚不能作為影像辨識能力的證據。

實作者：待填。　**審查者：**待填。
審查意見：待實際檢查後填寫。